4.2　実験 2-2：色空間クラスタリングを用いたマスク誘導型文字復元

実験 2-1 では，Otsu 二値化による誘導マスクを用いた拡散モデル（DDRM）が歴史的文献に対する劣化画像復元において一定の有効性を示した。しかし，同手法には，二値化マスクに起因するパッチ境界の継ぎ目や，赤字注記などの有色成分の再現が困難であるという課題が残存していた。18

本節では，Automatic Color Equalization（ACE）および複数色空間（RGB, Lab, Luv）を組み合わせた二段階クラスタリング（PCA→GMM）によって生成した高精度マスクを DDRM の復元過程に導入し，**マスク誘導型復元（mask-guided restoration）**としての効果を検証する。これにより，(i) 文字領域の精密な抽出，(ii) 実文献特有の多様な劣化要因の分離，(iii) 赤字注記などの彩色情報の保持，といった点で従来法を上回る復元を目指す。

比較対象として，以下の手法を評価する。

(i) **DDRM(Bin)**：Otsu 二値化により生成したテキストマスクを誘導信号として用いる従来型 DDRM。
(ii) **CycleGAN**：教師なし画像変換に基づく代表的復元モデル。

さらに，提案手法の構成要素の寄与を検証するため，以下のアブレーション実験を行う。

(a) **ACE 無効化**：色補正を行わずに GMM クラスタリングのみを適用した場合の性能。
(b) **一段階クラスタリング**：PCA→GMM の第二段階（劣化領域の再クラスタリング）を省略し，三値（背景・黒文字・劣化）の単純分離のみを用いた場合。

これらの比較により，色空間クラスタリングによるマスク生成が DDRM の復元品質に与える影響を詳細に分析し，特に淡い筆画の保持，背景均一性，および赤字注記の再構成といった観点から，提案手法の有効性を総合的に評価する。

4.2.1　提案手法の概要と貢献

本研究で提案するフレームワークは，ノイズマスキングの概念を導入している。ここでは，二値化によって生成された文字マスクを最終出力として用いるのではなく，DDRM の逆拡散過程におけるガイダンス信号として利用する [45, 49]。二値化処理はシミや退色を除去して文字領域を強調するが，本手法ではこれを復元方向の拘束条件として用いることで，文字形状に沿った復元を促し，背景ノイズや劣化成分を抑制する。

形式的には，ステップ t におけるネットワークの x_0 推定値を $\mathbf{x}_{\theta,t}$ とすると，マスク付き更新は次式で定義される。

$$\mathbf{x}_{\text{mask}} := (1 - \mathbf{H}) \odot \mathbf{x}_{\theta,t}, \tag{15}$$

ここで $\mathbf{H}$ は劣化オペレータ（Eq. (15) 参照），$\odot$ は画素単位の積を表す。この仕組みにより，汚損領域では更新が抑制され，一方で文字境界に沿った自然な筆画復元が促される。

しかし，ノイズマスキングの有効性は，入力マスクの精度に大きく依存する。従来広く用いられている二値化手法は，微弱な筆画を保持できず，輝度変動に敏感であるため，強い劣化を受けた領域を誤分類しやすい。

この問題を解決するため，本研究では二段階のマスク生成プロセスを採用する。まず，Automatic Color

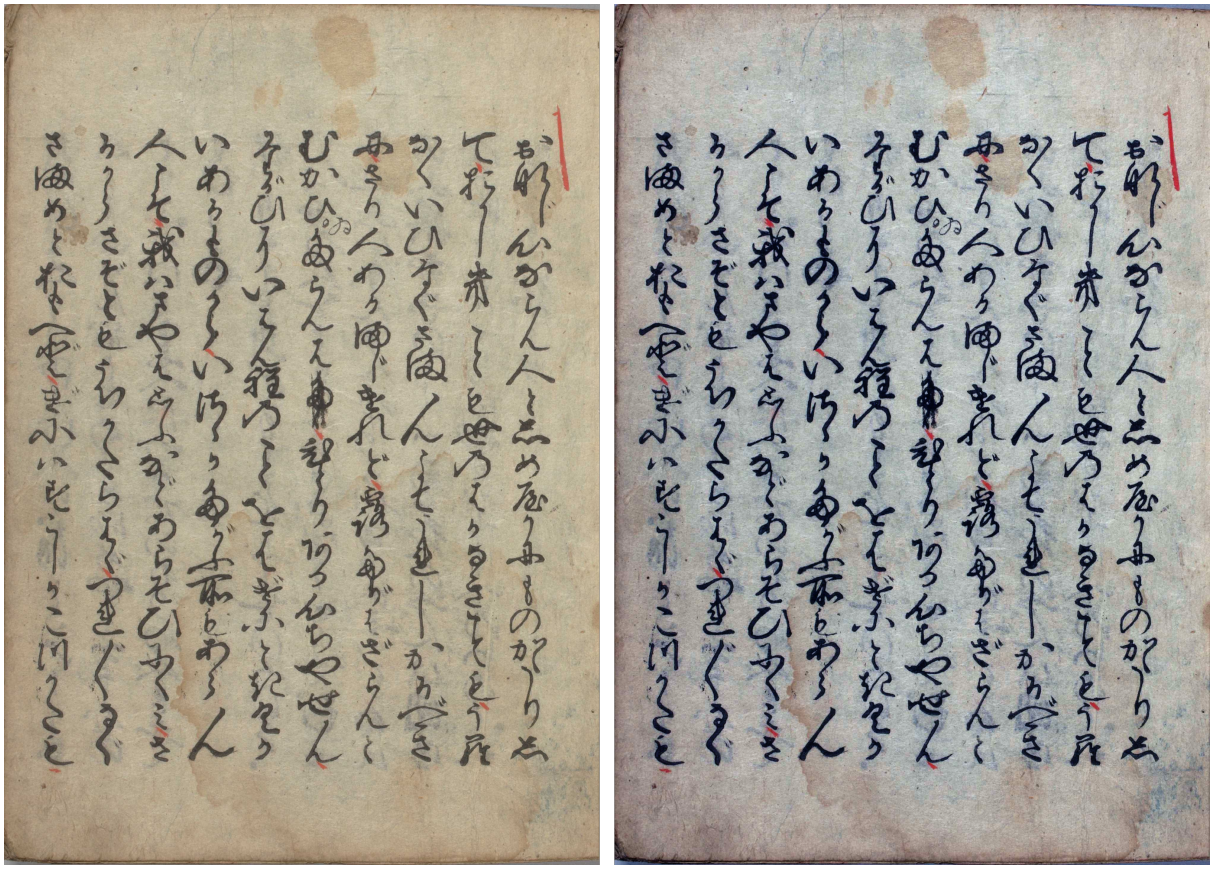

図20: **写本画像に対する ACE（Automatic Color Equalization）の効果.**（左）LabelImg により切り出した『徒然草』の原画像（CODH データセット）。（右）ACE により色正規化を施した結果であり，背景の黄ばみが軽減され，文字と紙面のコントラストが向上している。ACE は照明むらや経年変化による退色を補正し，後段のクラスタリングにおける文字領域と背景領域の識別性能を向上させる。

Equalization（ACE）[50] を適用し，照明や経年変化による色偏りを補正することで，文字と背景の色分布を正規化する (Figure 20)。次に，RGB，CIELab，CIELuv の各色空間の値を結合した特徴ベクトルを構築し，主成分分析（PCA）による次元削減の後，ガウス混合モデル（GMM）を用いた二段階クラスタリングを行う。この結果，各画像は背景・黒文字・赤文字・実劣化の 4 クラスに分類される。

クラスタリング手順は Figure 21 に示すとおりである。Stage 1 では輝度重視の特徴量 [L,a,b] を用いて PCA→GMM を適用し，背景・黒文字・劣化の 3 クラスを得る。続く Stage 2 では，Stage 1 で「劣化」に分類された画素のみを抽出し，色差に重点を置いた特徴量 [a,b,r,g] を用いて PCA→GMM（2 クラス）を実施する。ここでは「赤み（redness）」指標を基準として赤文字と実劣化を分離する。この二段階構造により，黒文字・赤文字・劣化領域を明確に分離できる。

生成された黒文字・赤文字マスクは微小ノイズを効果的に除去できる一方，劣化の激しい筆画では過度な処理により輪郭の丸みや筆画の分断を生じる可能性がある。そのため，本研究では過度な後処理を避け，文字形状保持を重視した制御を行っている。

得られた黒文字マスクは DDRM のノイズマスキング推論を誘導し，文字の微細構造を保持しつつ，

劣化領域を選択的に復元する。また，赤字を含む写本（例：徒然草）では，赤文字を復元過程に含めず，DDRM 後の出力に対して赤文字マスクを適用し，元画像から抽出した赤字を再合成することで，文字の明瞭性と色彩の真正性を両立させている。

さらに，本パイプラインはバッチ処理に対応しており，各入力画像に対して色補正後画像，4 クラスマスク，制御済みノイズ除去マスク，およびクラス面積比などの統計情報を自動生成できる。この構造により，大規模写本データセットの効率的処理が可能となる。

以上より，提案手法の主な利点は 3 点にまとめられる。(1) ACE により照明不均一と色ムラが補正され，クラスタリングの安定性が向上する。(2) ノイズマスキングにより，文字領域に限定した復元が可能となり，シミ抑制と筆画保持のバランスが最適化される。(3) 色空間情報を活用することで，赤字などのクラス特有マスクが生成でき，色認識型の復元が可能となる。これらにより，視認性・構造的忠実性・色彩的真正性の向上が実現し，古文書復元における強固な基盤を提供する。

4.2.2　実験設計

提案手法の有効性を検証するため，ROIS-DS 人文学オープンデータ共同利用センター（CODH, https://codh.rois.ac.jp/）が公開する古典籍の高解像度スキャン画像を用いて実験を行った [41]。これらのクリーン画像は，擬似劣化生成における ground truth として用いられた。

復元モデルには DDRM（Diffusion Denoising Restoration Model）を用い，人文学系写本データセットの 4,829 ページで学習した。学習時は計算資源の制約により，全画像を 128×128 にリサイズした。

モデルアーキテクチャには 3 チャネル U-Net を採用し，各層のチャネル数は 64 とし，4 つの Residual Block を配置した。また，構造理解を向上させるため，解像度 16 および 8 に Self-Attention を追加した。書誌分類ラベルを用いたクラス条件付き学習を導入し，クラスごとに異なる劣化傾向を反映できるようにした。学習は 1,000 ステップの線形ベータスケジュールと MSE Loss で行った。

復元性能の評価には PSNR[42]，SSIM[43]，および LPIPS（AlexNet）[51] を用いた。また，GMM による劣化マスクの変化量を測定し，ノイズ除去効果を定量的に評価した。さらに文献 [52, 53] に従い，入力の変動性や知覚品質に基づく分析も行った。

比較手法には (1) CycleGAN，(2) Otsu 法で生成した二値化マスクによる DDRM を採用した。CycleGAN では LANCZOS による線形 RGB 変換後にダウンサンプリングした画像を入力とし，復元後はバイキュービック補間でアップサンプリングした後，元画像から抽出した高周波成分を加算することで細部を強調した。Otsu 法は写本画像処理で広く用いられる基準手法として比較に適している。

擬似劣化を用いた評価には，劣化が少なく制御実験に適した平安期の写本『枕草子』を使用した。全 745 ページについて，LabelImg により写本領域をアノテーションした9。

擬似劣化生成には NVlabs の ocrodeg（https://github.com/NVlabs/ocrodeg）を用い，シミ・擦れ・カビなどの劣化を模倣した。劣化レベルは 4 段階に分けた（Figure 22）。

色空間クラスタリングにより，各画像を背景・黒文字・擬似劣化の 3 クラスに分割し，黒文字マスクをクリーン画像に適用して劣化画像を生成した (Figure 21)。

DDRM 推論では，画像を 1024×1024 にリサイズし，逆拡散ステップ数を 1,000 から 20 に削減した。復元ガイダンスには劣化マスクを用い，ガイダンス強度 η を 0.5 に設定した。拡散過程には $\beta_{\text{start}} = 0.0001$，$\beta_{\text{end}} = 0.02$，総ステップ数 1000 の線形スケジュールを用いた。

擬似劣化生成の詳細手順は Algorithm 2 に示す。

4.2.3　実写本への適用

本研究では，実運用における有効性を検証するため，江戸初期に筆写された古典写本『徒然草』を対象として実験を行った。同写本は，しみ，退色，にじみ（裏移り）などの自然劣化に加え，黒字と赤字が混在する点が特徴である。

まず，色空間クラスタリングを適用し，背景・黒文字・劣化・赤文字の四種のマスクを生成した。黒文字マスクを DDRM の条件入力として用い，さらにページごとに異なる紙地の色むらを抑えるため，『枕草子』の画像から抽出した標準化背景テクスチャを適用して画面全体の色調を整えた。

復元後には赤字マスクを重畳させることで，従来の二値化手法では保持が困難な赤字注記の色彩を維持しつつ，文字の可読性を向上させることができた。

4.2.4　復元結果の出力と分析

復元性能を評価するため，四段階の劣化強度（0.3，0.5，0.7，1.0）で擬似劣化を付与した写本画像を用い，提案するクラスタリングベースのマスク生成と，二値化ベースのベースライン手法 DDRM(Bin) とを比較した（図23）。

さらに，代表的な劣化強度において PSNR，SSIM，LPIPS の最小値・最大値・平均値・分散を算出し，統計的比較を行った（表4）。

図24 に示すように，劣化強度 1.0 の条件下でも提案手法は高い復元性能を示し，従来手法と比較して文字の細部表現・背景の均一化に優れている。

劣化強度の全範囲にわたり，PSNR と SSIM の双方で DDRM(Bin) を上回り，視覚的品質と構造的忠実度の向上を確認した。特に，PSNR は DDRM(Bin) に比べて約 10 dB の改善を示し，SSIM も約 0.17 向上した。

CycleGAN との比較においても，PSNR は約 2 dB，SSIM も約 0.09 向上し，構造保存の観点でも優れた性能を示した。

LPIPS に関しても提案手法が最も低い値を示し，知覚的品質の高さを裏付けている。

代表的な劣化強度における統計比較（表5）では，提案手法は最大 PSNR 27.6，平均 24.83 を達成し，DDRM(Bin)（最大 18.34，平均 13.86）を大きく上回った。SSIM においても最大値・平均値ともに高く，分散も小さく安定した復元性能を示した。

LPIPS については，最小値 0.2498 と DDRM(Bin) の 0.3711 より低く，知覚的類似度が高いことを示している。平均値（0.2789）および分散（0.0003）も小さく，忠実度と安定性の両面に優れることが明らかになった。

4.2.5　実写本『徒然草』への適用実験と考察

図25 は，『徒然草』の実写本画像に対する復元結果を示す。各行は異なるページを示し，第 1 列が劣化した原稿，第 2 列が CycleGAN，第 3 列が DDRM(Bin)，第 4 列が提案手法である。

提案手法は赤字注記を保持できる点で DDRM(Bin) に対し大きな優位性がある。赤字は校訂・意味情報を含む場合が多く，正確な保持は文献学的価値を高める上で重要である。

図中段では，標準化背景により背景しみや汚れが抑制されている一方，二値化では除去される裏移りが残存する例も見られ，半透明成分の扱いが依然として課題である。

下段では，退色した筆跡や薄い書き込みが適切に復元されており，従来手法で消失しやすい要素を保持

できることが確認できた。一部には虫食い状の新規アーティファクトが発生しており，これは元の紙地テクスチャと復元過程の補間の相互作用で生じたものである。

4.2.6　高解像度パッチベース推論による改善

ページ全体を直接復元すると，学習時の解像度との乖離により品質劣化やメモリ制約が生じるため，本研究では重なりを持つ 128×128 パッチに分割して推論を行った。

各パッチはガウシアン重み付けでブレンドし，境界の継ぎ目を抑制した。また，文字領域にはより高い重みを与えて筆画を保持した。

図26 に示すように，パッチベース推論は筆跡の鋭さ・薄い文字の再生・背景テクスチャの一貫性などの面で，ページ単位復元より高品質な結果を示した。

4.2.7　考察

本節では，本研究の目的，成果，残された課題，将来的展望，および文化的・学術的意義について議論する。

本研究の第一の目的は，色空間クラスタリングと拡散モデルを組み合わせた古典写本の復元手法の確立である。従来の二値化手法では淡い筆跡の喪失や赤字情報の消失が避けられず，構造的・情報的損失が大きい。本手法は，色空間特徴を用いて劣化要素を分離し，拡散過程に誘導マスクとして組み込むことで，これらの課題を解決した。

実験結果では，全劣化強度において PSNR が 10 dB 以上向上し，SSIM も大きく改善した。これらは単なる数値向上にとどまらず，従来では消失していた文字の復元，赤字注記の保持など，学術的価値に直結する改善である。

一方で課題も残る。まず，半透明インクによる裏移りの分離は依然として困難である。また，赤字と黒字が近接する領域ではマスクの曖昧さが生じやすい。

GMM を教師データとして CNN を訓練する案も検討したが，GMM の誤分類が学習に伝播して分類精度が不安定になる問題がある。深層学習を導入するには大量の高品質アノテーションが必要であり，古文書における現実的制約が大きい。

また，高解像度画像のページ全体推論では，局所的不連続や色調のばらつきが見られ，モデルの大域的理解の不足が示唆された。

将来的には，深層学習，適応クラスタリング，人手補正を統合したハイブリッド手法，DDPM ベースの後処理，専門家の評価を取り入れた新しい指標の開発などが有望である。

本研究は性能向上のみならず，文化財保存の観点から，AI が歴史資料の解釈・保存に寄与する新たな方向性を提示するものである。

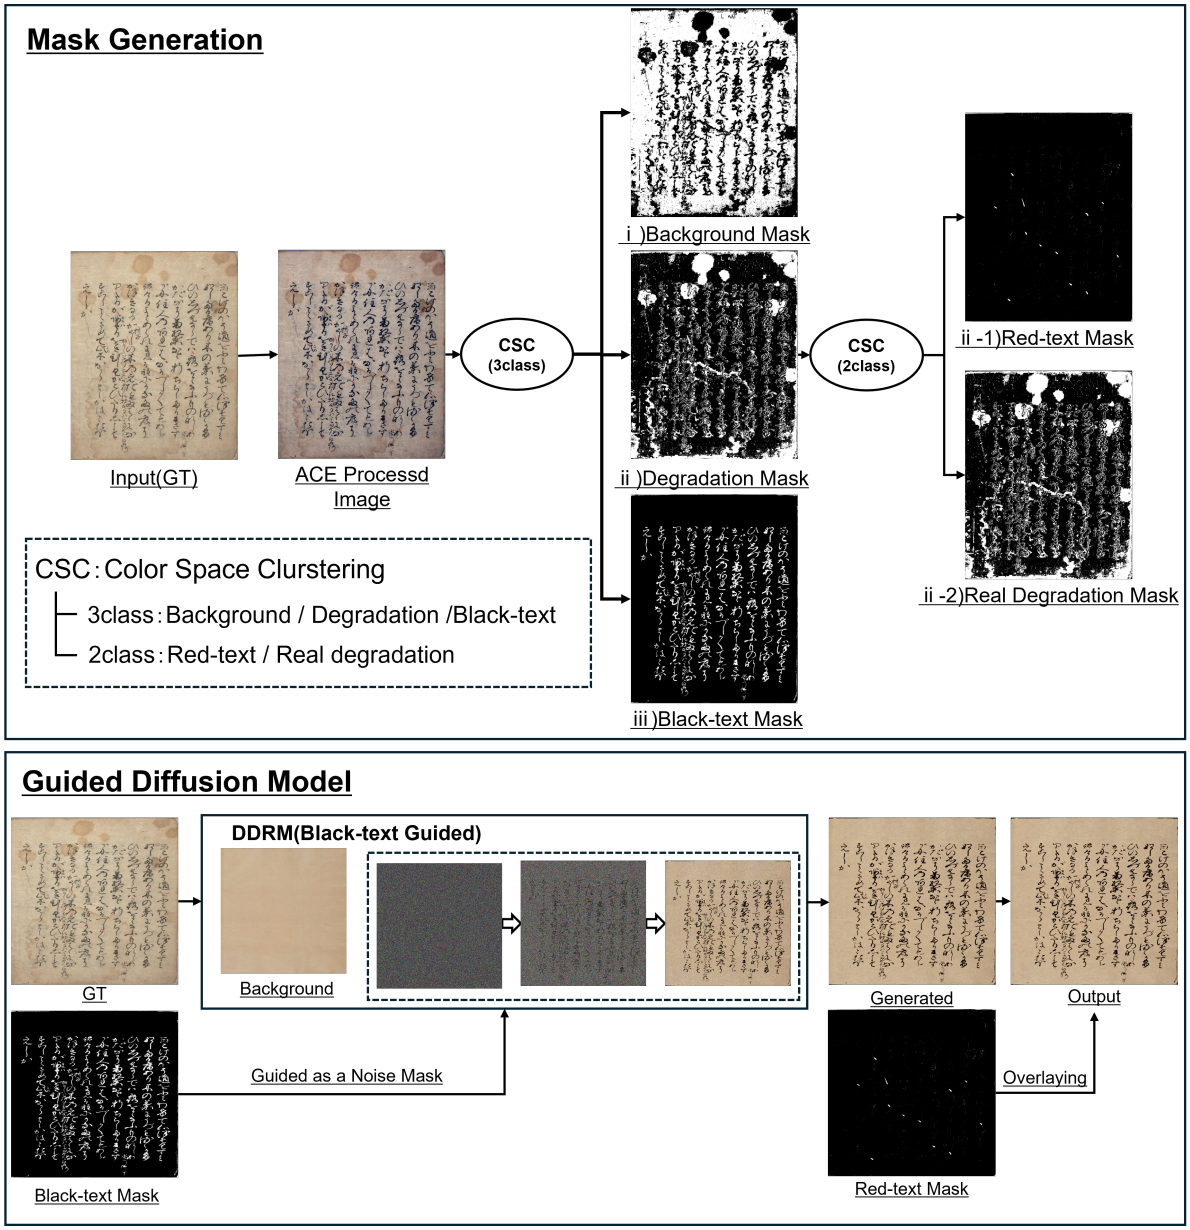

図21: **提案するマスク誘導型復元フレームワークの全体ワークフロー．**第 1 段階（**マスク生成**）：ACE 処理後の写本画像に対し，Color Space Clustering（CSC）によって背景・劣化・黒文字の三値に分離する。劣化領域は CSC に基づく第 2 段階クラスタリングにより「赤字」と「実劣化」に再分離される。第 2 段階（**誘導付き拡散復元**）：黒文字および背景マスクを DDRM へ誘導信号として入力し，劣化領域のみを選択的に復元する。赤字領域は拡散過程に含めず，最終出力にオーバーレイすることで彩色情報を保持する。本階層的マスク誘導設計により，汚れの抑制と文字形状の保持を両立し，赤字注記を含む色彩的忠実性も確保する。

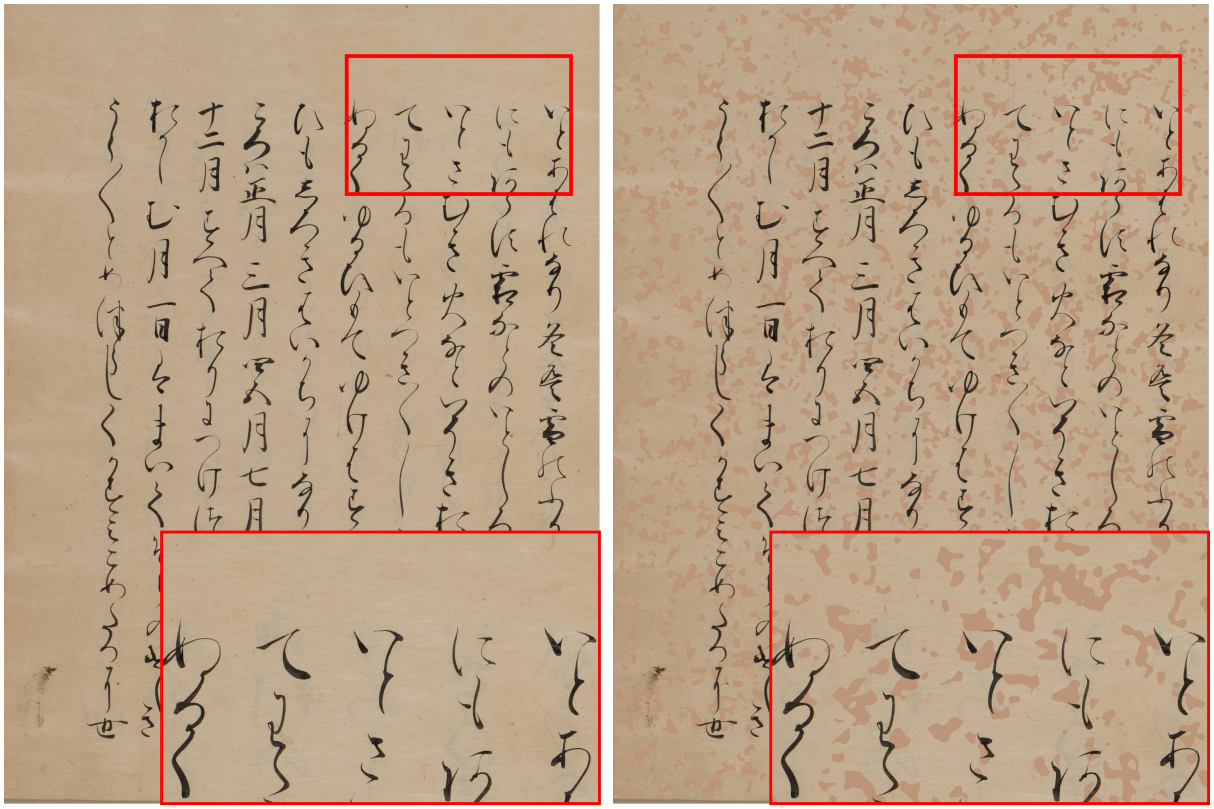

図22: **疑似劣化強度 1.0 における擬似劣化生成の例.**（左）LabelImg を用いて切り出した『徒然草』のクリーンページ（CODH データセット，高解像度スキャン）。（右）提案する疑似劣化生成パイプラインにより，劣化強度パラメータを 1.0 に設定して生成した劣化画像である。赤枠で示した領域には，退色・汚れ・表面のしみなどを模した疑似劣化が再現されており，これにより強度の高い劣化条件下で復元性能を定量的に評価可能となる。

Algorithm 2: Pseudo-degradation image generation pipeline

Input: I: Input document image ($H \times W \times 3$);
ρ: Stain density parameter (default 3×10^{-4});
σ: Stain size parameter (default 30);
α: Roughness parameter (default 2.0);
λ: Blending intensity (default 1.0);
C_{fixed}: Fixed stain color [R,G,B];
τ: Text detection threshold (default 150)

Output: I_{stained}: Stained image (text preserved);
I_{degraded}: Stained image (text affected)

(1) Text mask extraction

$I_{\text{gray}} \leftarrow \text{RGB2Gray}(I)$ using weights [0.299, 0.587, 0.114];
$M_{\text{text}} \leftarrow (I_{\text{gray}} < \tau)?1 : 0;$

(2) Stain mask generation

$N_{\text{blobs}} \leftarrow \lfloor \rho\, HW \rfloor;$
$S \leftarrow \text{ZeroMatrix}(H, W);$
for $i = 1$ **to** N_{blobs} **do**
  $(x, y) \leftarrow \text{RandomPosition}(H, W);$
  $S[x, y] \leftarrow 1;$

(3) Distance transform and smoothing

$D \leftarrow \text{DistanceTransform}(\neg S);$
$M_{\text{dist}} \leftarrow (D < \sigma)?1 : 0;$
$M_{\text{smooth}} \leftarrow \text{GaussianFilter}(M_{\text{dist}}, \sigma/(2\alpha));$
$M_{\text{norm}} \leftarrow \text{Normalize}(M_{\text{smooth}});$

(4) Noise generation and blob combination

$N \leftarrow \text{RandomNoise}(H, W);$
$N_{\text{smooth}} \leftarrow \text{GaussianFilter}(N, \sigma/(2\alpha));$
$N_{\text{norm}} \leftarrow \text{Normalize}(N_{\text{smooth}});$
$M_{\text{blob}} \leftarrow (M_{\text{norm}} \times N_{\text{norm}} > 0.5)?1 : 0;$

(5) Color stain mask creation

$M_{\text{stain}} \leftarrow M_{\text{blob}} \otimes C_{\text{fixed}};$

(6) Stain application (text-preserving)

$M_{\text{bg}} \leftarrow 1 - M_{\text{text}};$
$M_{\text{blend}} \leftarrow M_{\text{bg}} \odot (\text{Mean}(M_{\text{stain}}) > 10);$
$I_{\text{stained}} \leftarrow I \odot (1 - M_{\text{blend}}\lambda) + M_{\text{stain}} \odot (M_{\text{blend}}\lambda);$

(7) Stain application (text-affecting)

$M_{\text{area}} \leftarrow (\text{Mean}(M_{\text{stain}}) > 10)?1 : 0;$
$I_{\text{degraded}} \leftarrow I \odot (1 - M_{\text{area}}\lambda) + M_{\text{stain}} \odot (M_{\text{area}}\lambda);$

return $I_{\text{stained}}, I_{\text{degraded}}$

Notation:

$\otimes$: Broadcasting multiplication; $\odot$: Element-wise multiplication; $\neg$: Logical negation; Mean($\cdot$): Channel-wise mean; Normalize($\cdot$): Min-max normalization to [0,1].

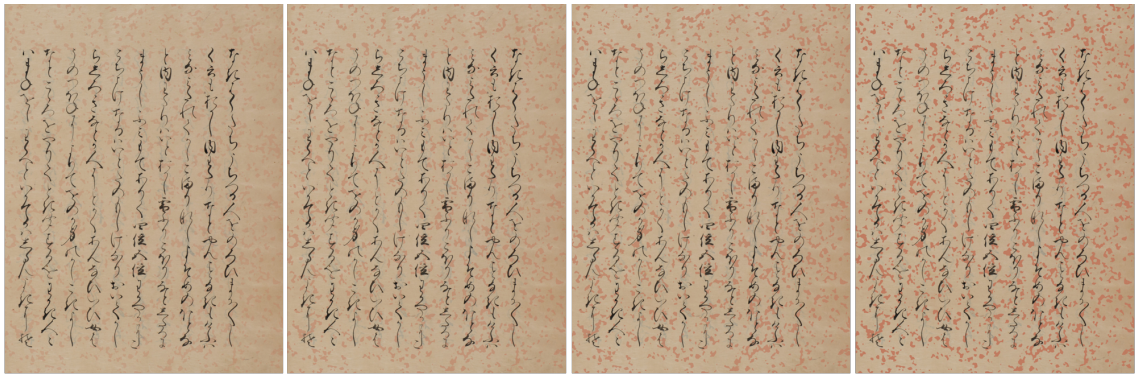

図23: **疑似劣化下における復元性能の評価.**『枕草子』データセットに対し，提案する疑似劣化生成パイプラインを用いて劣化強度 0.3，0.5，0.7，1.0 の擬似劣化画像を生成し，各手法の復元性能を比較した。提案手法は，全ての劣化強度において CycleGAN および二値化誘導 DDRM を上回る PSNR・SSIM の向上と LPIPS の低下を示し，高い復元忠実度を維持している。入力画像はいずれも『枕草子』（CODH データセット）の高解像度スキャンから LabelImg を用いて切り出したものである。

表4: **劣化強度（intensity）ごとの定量的評価結果.** 劣化強度 0.3〜1.0 の擬似劣化写本に対し，PSNR・SSIM・LPIPS の平均値を比較した。提案手法は全ての強度で CycleGAN および二値化誘導 DDRM を上回り，劣化が増大しても安定した復元性能を維持している。

	PSNR ↑			**SSIM ↑**			**LPIPS ↓**		
Int.	**CycleGAN**	**DDRM(Bin)**	**Ours**	**CycleGAN**	**DDRM(Bin)**	**Ours**	**CycleGAN**	**DDRM(Bin)**	**Ours**
0.3	22.08	14.25	24.50	0.8034	0.7246	0.8920	0.6360	0.4526	0.2821
0.5	22.04	14.82	24.65	0.7986	0.7667	0.8931	0.6493	0.4411	0.2802
0.7	21.96	14.70	24.76	0.7896	0.7711	0.8935	0.6643	0.4490	0.2788
1.0	21.85	13.86	24.83	0.7723	0.7440	0.8939	0.6832	0.4877	0.2789

表5: **劣化強度 1.0 における各手法の統計的比較.**『枕草子』の擬似劣化（intensity = 1.0）に対し，CycleGAN，二値化誘導 DDRM，提案手法の PSNR・SSIM・LPIPS の最小値・最大値・平均・分散を算出した。提案手法は最も高い平均 PSNR/SSIM を達成し，LPIPS の分散も最小であり，高い復元忠実度と安定性を併せ持つことが確認された。

Method	**PSNR ↑**				**SSIM ↑**				**LPIPS ↓**			
	Min	Max	Mean	Var	Min	Max	Mean	Var	Min	Max	Mean	Var
CycleGAN	12.35	20.39	17.16	1.3887	0.3894	0.9536	0.8369	0.0049	0.0160	0.4231	0.0893	0.0036
DDRM(Bin)	8.96	18.34	13.86	2.7422	0.5176	0.8369	0.7440	0.0028	0.3711	0.7014	0.4877	0.0033
Ours	19.20	27.60	24.83	1.2752	0.8384	0.8884	0.8736	0.0001	0.2498	0.4784	0.2789	0.0003

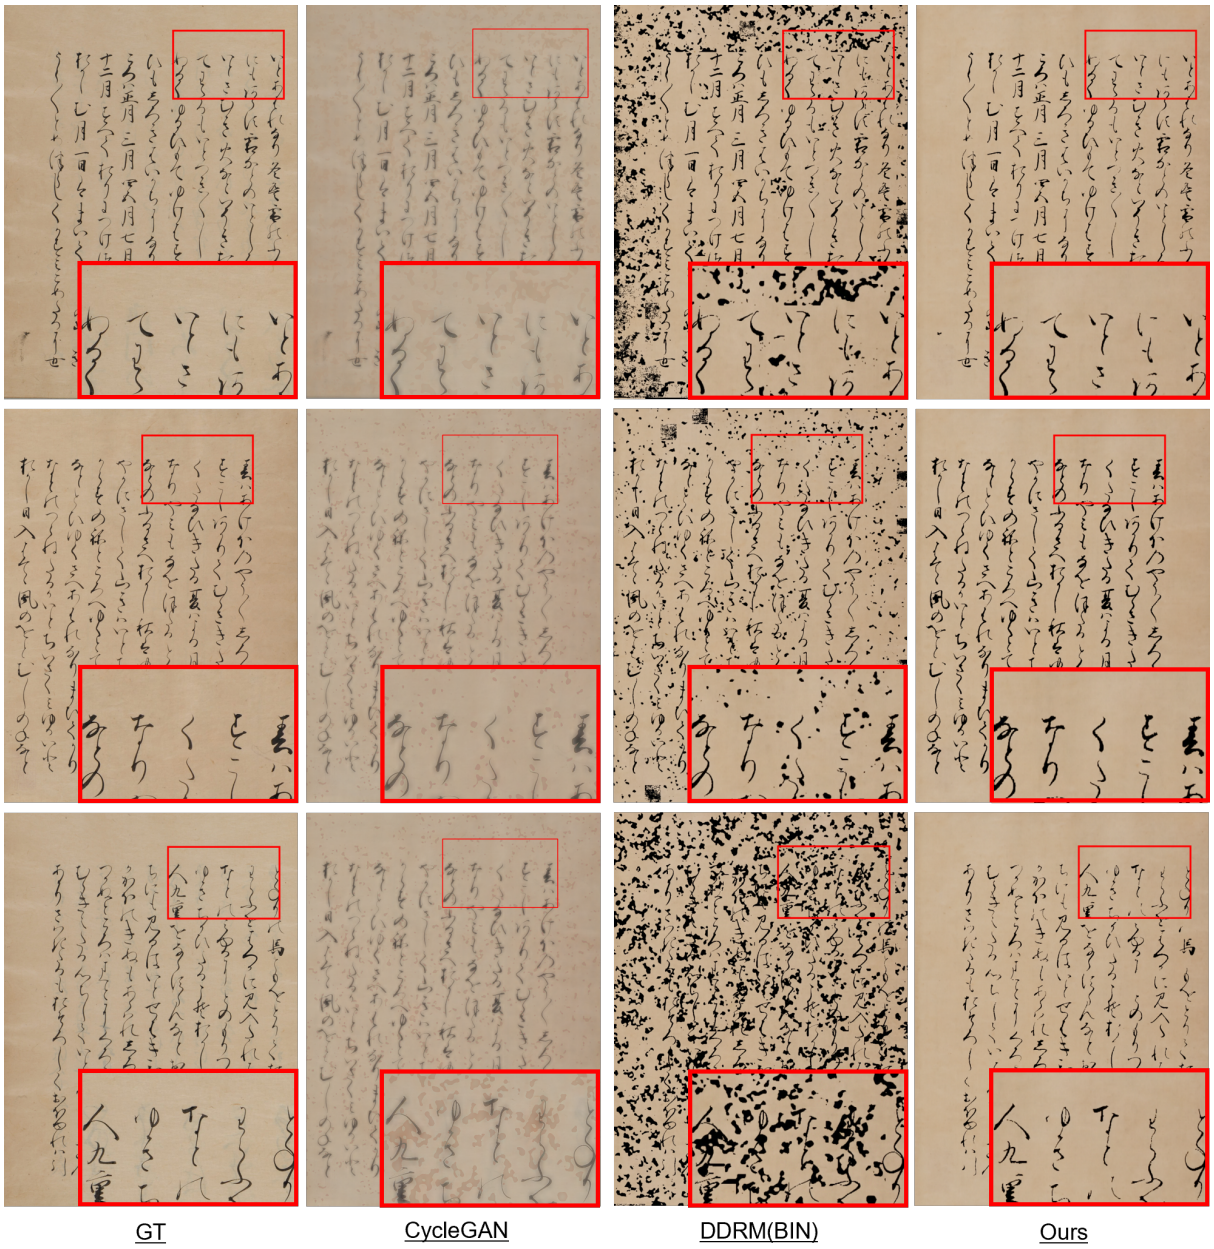

図24: **疑似劣化写本（『枕草子』）に対する復元結果の比較.** 各行は異なるページサンプルを示す。第 1 列：参照用のクリーン画像，第 2 列：CycleGAN による復元結果，第 3 列：二値化マスクを用いた DDRM の復元結果，第 4 列：提案するマスク誘導 DDRM による復元結果である。赤枠は拡大領域を示し，提案手法が微細な文字構造や背景の汚れをより効果的に除去していることが分かる。

図25: **実写本（『徒然草』）に対する復元結果の比較．**各行は異なる原ページを示す。第 1 列：劣化した原稿画像，第 2 列：CycleGAN による復元，第 3 列：二値化マスク誘導 DDRM による復元，第 4 列：提案するマスク誘導 DDRM による復元である。赤枠は拡大領域を示し，提案手法が実写本特有のしみ・退色・にじみを抑制しつつ文字構造を保持していることが分かる。これにより擬似劣化で学習したモデルが実写本に対しても高い汎化性能を示すことが確認できる。

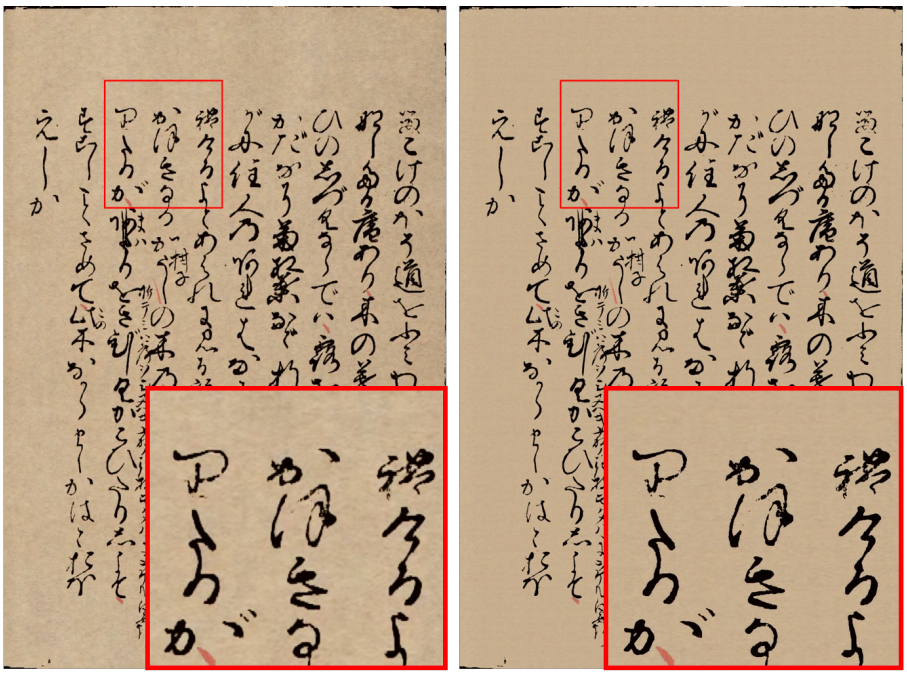

Ours　　Ours(High-resolution Restoration)

図26: ページ単位復元（左）と高解像度パッチベース復元（右）の比較．パッチベース復元では重なりを持つパッチに対して拡散推論を行い，境界をフェザーブレンドすることで，微細な筆画構造や弱い文字の復元が可能となる。また背景テクスチャの再現性も向上し，ページ全体としてより自然で鮮明な復元結果が得られる。

6　結論

本論文は、歴史的文献に対する劣化低減と文字保持を目的として、色空間クラスタリング（$ACE + PCA{\rightarrow}GMM$）により生成した誘導マスクと 拡散復元モデル（$DDRM$）を統合した**二段階復元フレームワーク**を提案した。提案手法は、局所的な筆画構造の復元とページ全体の明度・トーン整合を分離して扱う構成を特徴とし、徒然草および 伊曾保物語の実写本、ならびに 枕草子の擬似劣化データを用いて検証を行った。さらに、復元結果を入力とした文字検出実験を通じて、本手法が文献解析パイプライン全体に与える実用的効果を評価した。

実験結果より、局所復元（SR1）と大域復元（SR2）を分離した二段階 DDRM により、筆画の幾何構造の保持と背景ノイズの抑制を同時に達成できることを確認した。実写本においては、SSIM が一貫して最良の値を示し（徒然草：0.715、伊曾保物語：0.776）、brightness variance の改善および entropy の低下から、コントラスト強化と紙地の平滑化が定量的に裏付けられた。また、Otsu 二値化に代えて ACE と複数色空間特徴に基づく段階的クラスタリングを用いることで、淡い筆画の消失を抑えつつ赤字注記の再構成が可能となり、擬似劣化条件下では CycleGAN および DDRM(Bin) を全劣化強度において上回る PSNR・SSIM の向上と LPIPS の低下を達成した。文字検出を用いた検証では、復元画像を入力とした YOLOX による本文文字検出において、提案手法が未復元画像および比較手法に比べ、検出漏れと誤検出の双方を低減することを確認した。特に、しみや濃度むらに埋もれていた文字領域において再現率および Average Precision の向上が顕著であり、提案復元が筆画エッジの連続性と局所コントラストを安定化させ、後段の文字解析タスクに有効に寄与することが示された。この傾向は、kurtosis の増加と entropy の低下、ならびに局所 RMSE(a)–(c) の改善とも整合しており、鋭い筆画境界と平滑な背景の同時再構成が達成されていることを示唆する。

一方で，本研究にはいくつかの課題が残されている。従来のパッチ単位の復元では，パッチ境界におけるトーン不整合が継ぎ目として顕在化し，視認性および後段処理に悪影響を与えることが確認された。そこで本論文では，この継ぎ目問題を回避するため，ページを元解像度のまま扱う復元設計へ移行し，その実現手段として ACE による色補正と GMM クラスタリング（ACE + PCA→GMM）に基づく誘導マスク生成を導入した。これにより，しみ低減と筆画保持を両立しつつ，朱印・赤字注記の消失を抑えた復元を可能にしている。しかしながら，マスク生成は撮影条件や紙地の色分布、保存状態に依存するため，文献ごとの色特性が大きく異なる場合にはクラスタ境界が不安定になり，一部で過抑制（筆画の薄化）または抑制不足（しみ残り）が生じ得る。また，裏移りや赤字近傍に存在する半透明インク成分の分離は依然として難しく，より精緻な分離モデルの導入が課題である。加えて，実写本では厳密な clean GT が存在しないことから，PSNR や SSIM，文字検出精度はいずれも視覚的・文献学的改善度の近似指標に留まる。

今後は、濃度や信頼度に基づく連続値マスクを用いた Uncertainty-guided DDRM の導入、ページ全体の粗視化と高解像パッチ精緻化を組み合わせた多段・多解像度学習の検討が重要である。また、赤字や装飾文字を考慮したクラス条件付き拡散モデル、ならびに文字検出に加えて OCR や崩し字認識精度を含むエンドツーエンド評価の確立が求められる。

以上より、提案フレームワークは、しみ抑制・裏移り低減・筆画保持・色彩真正性に加え、文字検出性能の向上を同時に実現する有望な復元基盤であり、文化財の長期的デジタル保存のみならず、自動解析を含む文献研究基盤の高度化に寄与するものである。

謝辞

本研究を進めるにあたり、指導教員である孟林教授には、多くの研究生を抱えご多忙の中、研究方針の策定から論文執筆に至るまで、終始丁寧かつ真摯なご指導とご助言を賜りました。また、国際学会への参加や国際論文誌への投稿の機会をお与えいただき、それらの経験を通じて研究に対する理解を一層深めることができました。拙い点も多く、ご迷惑をお掛けすることもありましたが、常に温かくご指導くださったことに、心より感謝申し上げます。

研究室で共に切磋琢磨した同期、先輩、後輩、ならびに留学生の皆様には、日々の議論や協力を通じて多くの学びを得ることができました。研究に関する意見交換や情報共有を通して、新たな視点や知識を得る貴重な機会に恵まれたことに、深く感謝いたします。

日常生活および精神面において支えてくれた家族、特に両親には、この場を借りて心より感謝申し上げます。学費の支援をはじめ、学業と研究に専念できる環境を整えていただいたことで、充実した学生生活を送ることができました。

また、大学および大学院の六年間で出会ったすべての方々から、多くのご助言とご支援を賜り、研究者としてのみならず、一人の人間としても成長することができました。ここに改めて深く感謝の意を表します。

最後に、これまで私の学生生活を支えてくださったすべての方々に、心より御礼申し上げます。